Assignment 2 — CTC decoding for wav2vec2

1. Цель работы

Целью работы было:

1. реализовать несколько стратегий декодирования для CTC-модели `wav2vec2`;
2. сравнить greedy decoding, beam search, shallow fusion с языковой моделью и LM rescoring;
3. исследовать влияние гиперпараметров `beam_width`, `temperature`, `alpha`, `beta`;
4. сравнить поведение декодеров на in-domain и out-of-domain данных;
5. обучить доменную языковую модель для финансовой речи и сравнить её с общей языковой моделью.

---

2. Используемая модель

В работе использовалась модель:

- `facebook/wav2vec2-base-100h`

Это CTC-модель распознавания речи, которая выдаёт последовательность логитов по временным шагам, после чего применяется алгоритм декодирования.

---

3. Реализованные методы декодирования

Были реализованы следующие методы:

1. **Greedy decoding**
   - на каждом временном шаге выбирается наиболее вероятный токен;
   - затем применяется стандартная CTC post-processing процедура: удаление blank-токенов и схлопывание повторов.
2. **Beam search**
   - вместо одной гипотезы поддерживается несколько наиболее вероятных;
   - в экспериментах варьировался `beam_width`.
3. **Beam search + shallow fusion**
   - в score beam search добавляется вклад языковой модели KenLM;
   - использовались параметры `alpha` и `beta`.
4. **Beam search + LM rescoring**
   - сначала строится набор гипотез beam search;
   - затем гипотезы дополнительно переоцениваются языковой моделью.

---

4. Датасеты

Использовались два набора данных:

4.1 LibriSpeech test-other

Использовался как in-domain / near-domain тестовый набор.

4.2 Earnings22 test

Использовался как out-of-domain тестовый набор.
Он существенно сложнее, так как содержит финансовые звонки, специализированную лексику и более сложные акустические условия.

Во всех экспериментах использовалось по `200` сэмплов.

---

5. Языковые модели

5.1 General LM

В качестве общей языковой модели использовалась:

- `lm/3-gram.pruned.1e-7.arpa.gz`

5.2 Financial-domain LM

Дополнительно была обучена доменная языковая модель на:

- `data/earnings22_train/corpus.txt`

Эта модель использовалась для проверки, помогает ли доменная LM на финансовой речи.

---

6. Метрики

Качество оценивалось с помощью:

- **WER** — Word Error Rate
- **CER** — Character Error Rate

Также измерялось:

- **average sample time** — среднее время декодирования одного сэмпла

---

7. Базовые результаты

7.1 Baseline comparison

Dataset	Method	WER	CER	Avg time / sample
LibriSpeech test-other	greedy	0.1122	0.0381	0.1178 s

Dataset	Method	WER	CER	Avg time / sample
LibriSpeech test-other	beam	0.1107	0.0377	0.1420 s
LibriSpeech test-other	beam + LM (untuned)	0.1677	0.0518	0.3194 s
LibriSpeech test-other	beam + LM rescore (untuned)	0.1107	0.0377	0.1419 s
Earnings22 test	greedy	0.5497	0.2558	0.0966 s
Earnings22 test	beam	0.5494	0.2538	0.1184 s
Earnings22 test	beam + LM (untuned)	0.6039	0.2623	0.2406 s
Earnings22 test	beam + LM rescore (untuned)	0.5500	0.2541	0.1187 s

Анализ baseline

На `LibriSpeech test-other` beam search немного улучшил результат по сравнению с greedy:

- `WER: 0.1122 -> 0.1107`

На `Earnings22 test` beam search почти не изменил качество:

- `WER: 0.5497 -> 0.5494`

Базовое подключение LM с параметрами `alpha=0.5`, `beta=0.5` сильно ухудшило качество на обоих датасетах. Это показывает, что shallow fusion очень чувствителен к гиперпараметрам и без настройки может ухудшать результат.

---

8. Sweep по beam width

На `LibriSpeech test-other` были проверены значения:

- `beam_width = 1`
- `beam_width = 3`
- `beam_width = 10`
- `beam_width = 50`

Результаты

beam_width	WER	CER	Avg time / sample
1	0.1122	0.0381	0.1210 s
3	0.1117	0.0379	0.1173 s
10	0.1107	0.0377	0.1431 s
50	0.1110	0.0377	0.6482 s

Вывод

Увеличение `beam_width` от `1` до `10` слегка улучшает WER.
Однако дальнейшее увеличение до `50` почти не даёт выигрыша по качеству, но резко увеличивает время декодирования.
Наиболее разумным компромиссом в этих экспериментах оказался `beam_width = 10`.

---

9. Sweep по temperature

9.1 LibriSpeech test-other, greedy decoding

Проверялись значения:

- `T = 0.5, 0.8, 1.0, 1.2, 1.5, 2.0`

Во всех случаях результат оказался одинаковым:

- `WER = 0.1122`
- `CER = 0.0381`

9.2 Earnings22 test, greedy decoding

Проверялись те же значения температуры.
Во всех случаях результат также оказался одинаковым:

- `WER = 0.5497`
- `CER = 0.2558`

Объяснение

Для greedy decoding температура не влияет на итоговый результат, если декодирование основано на `argmax`.
Масштабирование логитов положительным коэффициентом не меняет индекс максимального элемента, а значит не меняет последовательность предсказаний.

---

10. Sweep по alpha и beta для shallow fusion

На `LibriSpeech test-other` проводился grid search по:

- `alpha ∈ {0.01, 0.05, 0.1, 0.5, 1.0, 2.0, 5.0}`
- `beta ∈ {0.0, 0.5, 1.0, 1.5}`

Лучший результат для shallow fusion

Лучшая конфигурация:

- `alpha = 0.01`
- `beta = 0.0`

Результат:

- `WER = 0.1102`

- `CER = 0.0377`

Вывод

После настройки shallow fusion начал слегка помогать по сравнению с обычным beam search:

- beam: `WER = 0.1107`
- best beam_lm: `WER = 0.1102`

При плохих значениях `alpha` и `beta` качество резко деградировало, вплоть до очень больших значений WER.
Это показывает, что LM integration крайне чувствительна к гиперпараметрам.

---

11. Sweep по alpha и beta для rescoring

На `LibriSpeech test-other` также проводился grid search для LM rescoring.

Лучший результат для rescoring

Лучшая конфигурация:

- `alpha = 0.05`
- `beta = 1.5`

Результат:

- `WER = 0.1100`
- `CER = 0.0374`

Вывод

LM rescoring в лучших настройках оказался немного лучше, чем:

- beam search
- best shallow fusion

Сравнение:

- beam: `WER = 0.1107`
- best beam_lm: `WER = 0.1102`
- best rescoring: `WER = 0.1100`

Разница небольшая, но в этих экспериментах rescoring оказался лучшим методом на LibriSpeech.

---

12. Перенос лучших конфигураций на Earnings22

Лучшие настройки, найденные на `LibriSpeech`, были перенесены на `Earnings22 test`.

Результаты

Method	Config	WER	CER
greedy	baseline	0.5497	0.2558
beam	beam_width=10	0.5494	0.2538
best beam_lm	alpha=0.01, beta=0.0	0.5473	0.2538
best rescoring	alpha=0.05, beta=1.5	0.5533	0.2538

Вывод

Перенос лучших настроек на out-of-domain данные дал ограниченный эффект:

- лучший shallow fusion немного улучшил WER;
- rescoring оказался хуже.

Это показывает, что настройки, найденные на LibriSpeech, не полностью переносятся на Earnings22.

---

13. Temperature sweep для лучшего shallow fusion на Earnings22

Для лучшего shallow fusion (`alpha=0.01`, `beta=0.0`) на `Earnings22 test` был проведён дополнительный sweep по температуре.

Результаты

Temperature	WER	CER
0.5	0.5491	0.2554
0.8	0.5458	0.2545
1.0	0.5473	0.2538
1.2	0.5446	0.2536
1.5	0.5461	0.2544
2.0	0.5566	0.2557

Вывод

В отличие от greedy decoding, для beam search with LM температура оказывает влияние на качество, так как меняет относительные вероятности гипотез и взаимодействие между акустической моделью и LM.

Лучшая температура:

- `T = 1.2`

Результат:

- `WER = 0.5446`
- `CER = 0.2536`

Это лучший результат для Earnings22 среди всех общих LM-конфигураций.

---

14. Сравнение general LM и financial-domain LM

Использовалась лучшая shallow-fusion конфигурация:

- `alpha = 0.01`
- `beta = 0.0`

Результаты

Dataset	LM	WER	CER	Avg time / sample
LibriSpeech test-other	general 3-gram LM	0.1102	0.0377	0.3157 s
LibriSpeech test-other	financial LM	0.1134	0.0383	0.3122 s
Earnings22 test	general 3-gram LM	0.5473	0.2538	0.2407 s
Earnings22 test	financial LM	0.5352	0.2532	0.2483 s

Вывод

Financial-domain LM:

- **ухудшает** качество на LibriSpeech;
- **улучшает** качество на Earnings22.

Это ожидаемый результат: доменная языковая модель лучше соответствует финансовой речи, но хуже работает на литературной/общей речи LibriSpeech.

---

15. Финальные лучшие результаты

Лучший результат на LibriSpeech test-other

Лучший результат в проведённых экспериментах:

- **beam_lm_rescore**
- `alpha = 0.05`
- `beta = 1.5`
- `WER = 0.1100`
- `CER = 0.0374`

Лучший результат на Earnings22 test

Лучший результат в проведённых экспериментах:

- **beam_lm**
- `alpha = 0.01`
- `beta = 0.0`
- `temperature = 1.0`

- **financial-domain LM**
- `WER = 0.5352`
- `CER = 0.2532`

---

16. Основные выводы

В ходе работы были реализованы и протестированы четыре стратегии CTC decoding:

- greedy decoding;
- beam search;
- beam search with shallow fusion;
- beam search with LM rescoring.

Эксперименты показали следующее:

1. **Beam search** даёт небольшое улучшение по сравнению с greedy decoding, особенно на LibriSpeech.
2. **Beam width** улучшает качество только до определённого момента; слишком большой beam становится слишком дорогим по времени.
3. **Temperature scaling** не влияет на greedy decoding, так как `argmax` не меняется.
4. **Shallow fusion** очень чувствителен к `alpha` и `beta`.
5. После настройки shallow fusion начинает давать небольшой выигрыш.
6. **LM rescoring** на LibriSpeech оказался немного лучше обычного beam search и shallow fusion.
7. На `Earnings22` перенос лучших конфигураций с LibriSpeech помогает ограниченно.
8. **Domain shift** между LibriSpeech и Earnings22 очень велик: WER на Earnings22 существенно выше.
9. **Financial-domain LM** ухудшает качество на LibriSpeech, но улучшает его на Earnings22.
10. Лучший результат на Earnings22 был получен именно с доменной LM, что подтверждает важность соответствия языковой модели домену тестовых данных.

---

17. Заключение

В этой работе были реализованы и исследованы разные подходы к CTC decoding для wav2vec2. Показано, что:

- beam search даёт небольшой выигрыш по сравнению с greedy;
- shallow fusion без настройки может ухудшать качество;
- после подбора гиперпараметров LM начинает приносить пользу;
- доменная языковая модель особенно важна для out-of-domain речи.

Итоговый лучший результат на `Earnings22` был достигнут с использованием:

- beam search with shallow fusion,
- financial-domain LM,
- `alpha = 0.01`,
- `beta = 0.0`,
- `temperature = 1.0`.

---

18. Ссылка на репозиторий

https://github.com/demokritfromabyss/speech_recognition_generation/tree/main/assignment2